



UNIVERSIDADE FEDERAL DO PIAUÍ
CAMPUS SENADOR HELVÍDEO NUNES DE BARROS
CURSO DE BACHARELADO EM SISTEMAS DE INFORMAÇÃO

SEGMENTAÇÃO DE IMAGENS

Lazaro Claubert Sousa Rodrigues Oliveira
Lizzandro Welson Holanda de Carvalho Galdino
Mauricio Benjamin da Rocha
Pedro Antonio Vital de Sousa Carvalho

Picos PI

2024

UNIVERSIDADE FEDERAL DO PIAUÍ
CAMPUS SENADOR HELVÍDEO NUNES DE BARROS
CURSO DE BACHARELADO EM SISTEMAS DE INFORMAÇÃO

SEGMENTAÇÃO DE IMAGENS

Lazaro Claubert Sousa Rodrigues Oliveira
Lizzandro Welson Holanda de Carvalho Galdino
Mauricio Benjamin da Rocha
Pedro Antonio Vital de Sousa Carvalho

Relatório técnico apresentado na Universidade Federal do Piauí como parte integrante do trabalho em equipe sobre a "Segmentação de Imagens utilizando a base ultrasound.zip", no contexto do curso Sistemas de Informação. Este relatório tem como objetivo analisar e documentar as etapas, metodologias e resultados obtidos durante a execução do projeto.

Picos PI

2024

Sumário

1	INTRODUÇÃO	3
1.1	Objetivos	3
2	RELATO DO EXPERIMENTO	4
2.1	Segmentação usando o algoritmo K-means	4
2.2	Segmentação usando algoritmos de Niblack e Otsu	4
2.3	Deteccção de bordas utilizando o método de Marr-Hildreth	5
2.4	Deteccção de bordas usando MeanShift juntamente com sobel	7
2.5	Método para escolha de foreground e background automaticamente	8
2.6	Métricas de acurácia para Segmentação	9
3	CONCLUSÕES	12
	REFERÊNCIAS	13

1 Introdução

A segmentação de imagens é uma disciplina crucial no campo da visão computacional, desempenhando um papel essencial em uma variedade de aplicações, desde diagnósticos médicos até reconhecimento de objetos em veículos autônomos (PATIL; DEORE, 2013). Este relatório se concentra na prática da segmentação de imagens, com ênfase na aplicação da técnica à base de dados "ultrasound.zip".

A segmentação de imagens envolve a divisão de uma imagem em regiões distintas com base em características específicas, permitindo uma interpretação mais detalhada e precisa do conteúdo visual (FERREIRA, 2023). Tais características variam desde cores, intensidade, objetos de interesse, formatos, entre outros fatores que podem vir a relevantes dependendo da problemática abordada (BRAUN, 2023). Essa abordagem é fundamental para extrair informações relevantes e facilitar a compreensão de imagens em diversas áreas (GONZALEZ; WOODS, 2000).

Neste trabalho, exploramos os desafios e nuances da segmentação de imagens ao lidar com a base de dados "ultrasound.zip". Dada a natureza específica das imagens de ultrassom, o processo requer abordagens especializadas para obter resultados precisos. Ao longo deste relatório, detalharemos as metodologias utilizadas, os obstáculos enfrentados e os resultados obtidos durante a análise e aplicação da segmentação de imagens nesse contexto específico.

1.1 Objetivos

Revisão de literatura sobre métodos de segmentação visando avaliar a possibilidade da ocorrência de melhores resultados em imagens específicas devido a divergência nos dados. Ao final do relatório obter insights valiosos para trabalhos futuros.

2 Relato do Experimento

Os experimentos foram realizados com base na tarefa solicitada, onde foram divididos por seção, sendo elas detecção de bordas usando o algoritmo K-means, segmentação usando Niblack e Otsu, detecção de bordas utilizando o método de Marr-Hildreth, algoritmo MeanShift junto com Sobel para detecção de bordas, criação de um método para escolher o foreground (Parte principal da imagem) e o background (Fundo da imagem) automaticamente e métricas de acurácia para segmentação.

2.1 Segmentação usando o algoritmo K-means

O algoritmo K-Means, também conhecido como K-Médias, é projetado para realizar a classificação de informações com base nos próprios dados, tornando-se uma ferramenta valiosa na mineração de dados não supervisionada. Ao contrário de métodos que exigem pré-classificação humana, o K-Means opera automaticamente, analisando e comparando os valores numéricos dos dados fornecidos ([MORAES, 2021](#)).

O algoritmo lida com conjuntos de dados organizados em tabelas, onde cada coluna representa uma dimensão e cada linha contém informações correspondentes a essas dimensões. O objetivo do K-Means é atribuir cada linha a uma classe (ou cluster) específica, sendo necessário que o usuário especifique a quantidade desejada de classes.

Para realizar essa tarefa, o algoritmo compara os valores de cada linha por meio de cálculos de distância. A fórmula utilizada para calcular essa distância varia de acordo com a quantidade de atributos presentes na tabela de dados ([ALMEIDA, 2015](#)). Posteriormente, o algoritmo itera sobre o conjunto de dados, calculando centroides para cada classe. À medida que o algoritmo prossegue, os valores dos centroides são refinados pela média dos atributos das ocorrências associadas a cada centroide.

Durante o processo iterativo, o K-Means gera k centroides e reorganiza as ocorrências na tabela com base em suas distâncias relativas aos centroides. Esse ciclo de cálculos, ajustes de centroides e realocações continua até que a convergência seja alcançada, resultando em clusters que representam agrupamentos naturais nos dados, sem a necessidade de intervenção humana na supervisão do processo ([MORAES, 2021](#)).

2.2 Segmentação usando algoritmos de Niblack e Otsu

O algoritmo de Niblack é um método local de limiarização que considera a média e o desvio padrão local dos pixels ao redor de cada ponto na imagem. Desenvolvido por

Wayne Niblack, esse algoritmo é especialmente útil em cenários onde a iluminação varia significativamente ao longo da imagem, impactando a eficácia dos métodos globais de limiarização (ALMEIDA, 2015).

A abordagem do algoritmo de Niblack baseia-se na comparação de cada pixel com um limiar local calculado para a vizinhança ao seu redor. A fórmula geral para calcular o limiar local é $T(x, y) = m(x, y) + k \cdot s(x, y)$, onde $T(x, y)$ é o limiar local, $m(x, y)$ é a média local, $s(x, y)$ é o desvio padrão local, e k é um fator ajustável.

Essa abordagem adaptativa permite ao algoritmo de Niblack lidar com mudanças locais na iluminação, conferindo-lhe robustez em situações onde métodos globais podem falhar. A escolha dos parâmetros, como o tamanho da vizinhança e o valor de k , é crucial para otimizar o desempenho do algoritmo em diferentes contextos.

Por outro lado, o método de Otsu é um algoritmo global de limiarização que visa encontrar automaticamente um limiar ótimo para dividir uma imagem em duas classes, geralmente objeto e fundo. O algoritmo de Otsu utiliza a variância intra e interclasses para calcular o limiar ideal, minimizando a variância dentro das classes e maximizando a variância entre as classes.

O algoritmo de Otsu calcula as probabilidades de intensidade para cada pixel e, a partir dessas probabilidades, determina o limiar que maximiza a variância interclasse. Essa abordagem global é eficaz em cenários onde a variabilidade de intensidade entre as classes é significativa.

Em resumo, enquanto o algoritmo de Niblack é eficiente em situações com variação local de iluminação, o método de Otsu é mais apropriado para casos onde se busca um limiar global otimizado para a separação de classes.

2.3 Detecção de bordas utilizando o método de Marr-Hildreth

O método de Marr-Hildreth, também conhecido como operador de Laplace do gaussiano, é uma técnica utilizada em processamento de imagem para detecção de bordas. Ele possui várias vantagens em relação aos métodos baseados em gradiente, como o Sobel ou o Roberts (SPONTÓN; CARDELINO, 2015). Uma das principais vantagens do método Marr-Hildreth é sua capacidade de suavização e detecção de bordas simultâneas. Ao aplicar a convolução com o operador Laplace do gaussiano, o método realiza uma filtragem que atua como um filtro passa-baixa, suavizando a imagem (MARR; HILDRETH, 1980). Isso é vantajoso porque reduz o impacto de ruídos na detecção de bordas, proporcionando resultados mais robustos e menos sensíveis a variações de intensidade pixel a pixel.

Outra característica importante é a capacidade do método de produzir respostas de borda com largura constante. Isso significa que, ao contrário de alguns métodos baseados

em gradiente, o Marr-Hildreth tende a gerar bordas com uma resposta mais consistente em termos de largura, o que é crucial para uma representação precisa das características da imagem (SCHOENMAKER; GROOT,). Além disso, o Marr-Hildreth oferece uma resposta de zero-cruzamento, que ocorre quando há uma mudança de sinal na derivada segunda da intensidade da imagem. Essa característica contribui para a localização precisa das bordas, uma vez que os pontos de zero-cruzamento indicam os locais exatos onde as transições de intensidade ocorrem .

Contudo, é importante mencionar que o método Marr-Hildreth também apresenta desafios, como a sensibilidade a escolhas inadequadas de parâmetros, como o desvio padrão do filtro gaussiano. Essa sensibilidade pode impactar a detecção de bordas em diferentes escalas. Em resumo, enquanto o Marr-Hildreth tem suas vantagens, é crucial considerar a natureza específica da aplicação e as características da imagem ao escolher o método mais apropriado para detecção de bordas. A Figura 1 apresenta uma imagem da base sem nenhuma modificação, já a Figura 2 apresenta a imagem processada pelo método.




Figura 1 – Imagem normal da base




Figura 2 – Imagem após a detecção de bordas Marr-Hildreth

2.4 Detecção de bordas usando MeanShift juntamente com sobel

A detecção de bordas através da combinação do algoritmo MeanShift para segmentação e do operador de Sobel para realce de bordas é uma técnica poderosa no processamento de imagens. Essa abordagem se destaca pela capacidade de integrar as vantagens de ambos os métodos, proporcionando segmentações mais precisas em cenários nos quais as informações de borda são cruciais (SPONTÓN; CARDELINO, 2015).

O operador de Sobel atua inicialmente sobre a imagem, realçando transições abruptas de intensidade e destacando as bordas. Essa etapa é crucial, pois prepara a imagem ao criar regiões homogêneas em torno das bordas, facilitando a tarefa subsequente do MeanShift (MARR; HILDRETH, 1980). O algoritmo MeanShift, por sua vez, aproveita as características destacadas pelo Sobel para realizar a segmentação. Ao agrupar pixels semelhantes em regiões coesas, o MeanShift utiliza a informação de borda realçada para guiar o processo de agrupamento, resultando em segmentações mais refinadas e alinhadas com as transições de intensidade significativas.

A eficácia dessa abordagem depende consideravelmente da escolha adequada de parâmetros, como a largura da janela no MeanShift e a sensibilidade do operador de Sobel. A otimização desses parâmetros é essencial para alcançar um desempenho ideal, adaptando-se às características específicas da imagem e aos requisitos da aplicação em questão. Experimentar diferentes configurações é, portanto, uma prática recomendada para afinar a detecção de bordas e a segmentação, garantindo que a técnica atenda de forma eficaz às necessidades específicas de uma aplicação particular.

2.5 Método para escolha de foreground e background automaticamente

Inicialmente, a imagem é submetida a um desfoque gaussiano para suavização e redução de detalhes indesejados. Em seguida, o algoritmo K-means é empregado, agrupando os pixels da imagem em dois clusters distintos. A identificação do cluster que representa o background é realizada através da contagem dos rótulos atribuídos a cada pixel. A partir dessa identificação, máscaras são geradas, delineando áreas correspondentes ao foreground e ao background. A aplicação destas máscaras na imagem original é efetuada utilizando operações bitwise, resultando na segmentação eficaz da imagem em regiões de interesse distintas. Este processo automatizado proporciona uma abordagem robusta para a seleção de foreground e background, reduzindo a necessidade de intervenção manual e contribuindo significativamente para análises subsequentes em contextos que demandam uma clara distinção entre as áreas de interesse.

A Figura 3 ilustra uma imagem qualquer da base que após ser processada pelo método nos permitira obter nossa zona de interesse, sendo ela o foreground apresentado na Figura 4 e seu fundo apresentado pela Figura 5




Figura 3 – Imagem de entrada




Figura 4 – Foreground separado automaticamente




Figura 5 – Background separado automaticamente

2.6 Métricas de acurácia para Segmentação

Foram utilizadas as métricas IoU (Intersection over Union) e Dice, também conhecido como índice de Sorensen-Dice, para avaliar a qualidade de segmentação em tarefas de visão computacional, como a segmentação de objetos em imagens.

IoU (Intersection over Union): A métrica IoU quantifica a sobreposição entre a área prevista pela segmentação e a área verdadeira (rótulo) do objeto. Sua fórmula é dada por $IoU = \frac{\text{Área da Interseção}}{\text{Área da União}}$, gerando valores no intervalo de 0 a 1. Essa métrica é particularmente útil em cenários onde a precisão espacial da segmentação é crítica, como

na segmentação de objetos em imagens médicas ou na detecção de objetos em tarefas de visão computacional. A variação mIoU é frequentemente utilizada em competições de segmentação, calculando o IoU para cada classe e tirando a média desses valores para uma avaliação abrangente da qualidade da segmentação em várias classes.

Índice de Sorensen-Dice (Coeficiente Dice): O coeficiente Dice mede a sobreposição entre duas regiões e gera valores no intervalo de 0 a 1. Sua fórmula é $DSC = \frac{2 \times |A \cap B|}{|A| + |B|}$. Essa métrica é valiosa em tarefas de segmentação, especialmente em imagens médicas, onde a sobreposição precisa entre as áreas segmentadas e as regiões verdadeiras é crucial. O Dice pode ser calculado para cada classe ou região individualmente, e a média desses valores, conhecida como média do coeficiente Dice (mDSC), é utilizada para uma avaliação global da precisão da segmentação em relação aos rótulos verdadeiros.

Em resumo, tanto o IoU quanto o índice de Sorensen-Dice são métricas essenciais para avaliar a qualidade da sobreposição e a precisão espacial das segmentações em tarefas de visão computacional, proporcionando medidas quantitativas da qualidade do modelo em relação aos rótulos verdadeiros. As Figuras 6 e 7 ilustram os resultados obtidos calculando o desempenho da segmentação entre Otsu e Niblack




Figura 6 – Formula de IoU




Figura 7 – Formula de Dice

3 Conclusões

Ao final desse experimento podemos concluir que existem diversas formas de processar imagens, desde detecção de bordas a meio de segmentação para separar imagens em parte e/ou regiões de forma que dependendo do nosso problemas abordado, possamos vir a definir um método mais adequado ou eficiente para a mesma através do conhecimento e experimentação de diversos métodos. Para o experimento realizado comparando Otsu e Dice na problemática da base de dados trabalhada pode-se observar que para este problema Otsu foi superior em sua grande maioria, entretanto em determinados problemas Dice pode vir a ser relevante também.

Referências

- ALMEIDA, L. H. E. V. d. *Binarização de imagens de documentos utilizando estimativa local de largura de traço*. Dissertação (Mestrado) — Universidade Federal de Pernambuco, 2015. Citado 2 vezes nas páginas 4 e 5.
- BRAUN, V. C. *Segmentação de regiões de interesse em imagens de plantas da subespécie *Acer palmatum**. Dissertação (B.S. thesis) — Universidade Tecnológica Federal do Paraná, 2023. Citado na página 3.
- FERREIRA, M. d. S. Combinando algoritmos de agrupamento e superpixels para a segmentação de lesões melanocíticas em imagens macroscópicas. Universidade Federal do Pampa, 2023. Citado na página 3.
- GONZALEZ, R. C.; WOODS, R. E. *Processamento de imagens digitais*. [S.l.]: Editora Blucher, 2000. Citado na página 3.
- MARR, D.; HILDRETH, E. Theory of edge detection. *Proceedings of the Royal Society of London. Series B. Biological Sciences*, The Royal Society London, v. 207, n. 1167, p. 187–217, 1980. Citado 2 vezes nas páginas 5 e 7.
- MORAES, E. F. d. T. Segmentação de imagens de hematoxilinaeosina ((h&e) utilizando análise de agrupamentos k-means. Universidade Federal de São Paulo, 2021. Citado na página 4.
- PATIL, D. D.; DEORE, S. G. Medical image segmentation: a review. *International Journal of Computer Science and Mobile Computing*, v. 2, n. 1, p. 22–27, 2013. Citado na página 3.
- SCHOENMAKER, R.; GROOT, J. de. Detecting edges using the marr-hildreth approach. *8th SC@ RUG 2010-2011*, p. 7. Citado na página 6.
- SPONTÓN, H.; CARDELINO, J. A review of classic edge detectors. *Image Processing On Line*, v. 5, p. 90–123, 2015. Citado 2 vezes nas páginas 5 e 7.